57º SBPO
SIMPÓSIO BRASILEIRO DE PESQUISA OPERACIONAL
Gramado • RS
DE 5 A 9 DE OUTUBRO DE 2025

Otimização Multiobjetivo da Logística de Resíduos Perigosos no Descomissionamento Naval: uma Adaptação Experimental com NSGA-II

Rhaiany Souza
Universidade Federal Fluminense — PPG-MCCT
Disciplina: Inteligência Computacional Aplicada (ICA)
rhaiany_souza@id.uff.br

RESUMO

Este trabalho investiga uma adaptação experimental da logística de resíduos perigosos oriundos do descomissionamento naval. Inspirada no problema de localização e roteirização de Rabbani et al. (2018), a formulação considera a atribuição de lotes a instalações receptoras e a formação simplificada de viagens, com três objetivos: custo total, risco no transporte e risco das instalações. Emprega-se o algoritmo NSGA-II em uma implementação modular para explorar soluções não dominadas sujeitas a capacidade, elegibilidade e incompatibilidade. Dois cenários ilustrativos foram executados com 100 indivíduos, 200 gerações e semente fixa, resultando em 55 e 68 soluções não dominadas viáveis distintas, respectivamente. As instalações e os parâmetros logísticos são sintéticos, e as viagens não incorporam roteirização de múltiplas paradas. Os resultados ilustram a viabilidade computacional do protótipo, mas não constituem validação operacional nem comprovação de otimalidade global.

PALAVRAS CHAVE. Otimização multiobjetivo. NSGA-II. Resíduos perigosos.

Tópicos (indique, em ordem de PRIORIDADE, o(s) tópicos(s) de seu artigo)

ABSTRACT

This study investigates an experimental adaptation of hazardous-waste logistics arising from ship decommissioning. Inspired by the location-routing problem studied by Rabbani et al. (2018), the formulation assigns waste lots to receiving facilities and builds simplified vehicle trips, while minimizing total cost, transportation risk, and facility risk. A modular NSGA-II implementation searches for nondominated solutions subject to capacity, eligibility, and incompatibility constraints. Two illustrative scenarios were evaluated using 100 individuals, 200 generations, and a fixed random seed, yielding 55 and 68 distinct feasible nondominated solutions, respectively. Facilities and logistics parameters are synthetic, and trips do not involve multistop routing. The findings illustrate the computational feasibility of the prototype but do not establish operational validity or global optimality.

KEYWORDS. Multiobjective optimization. NSGA-II. Hazardous waste.

Paper topics (indicate in order of PRIORITY the paper topic(s))

1. Introdução

O descomissionamento naval exige identificar, separar, transportar e destinar materiais perigosos de forma compatível com requisitos técnicos e ambientais. O Inventário de Materiais Perigosos (IHM) contribui para reconhecer materiais e suas localizações a bordo; entretanto, não determina, por si só, os custos, riscos e capacidades da rede receptora. Escolhas de menor custo podem apresentar risco maior e vice-versa.

Rabbani et al. [2018] propõem um problema industrial multiobjetivo de localização e roteirização de resíduos perigosos com incompatibilidades entre materiais e decisões de instalações e rotas. A presente proposta *não reproduz integralmente* aquela formulação. Seu escopo é mais restrito: instalações fixas, lotes indivisíveis, atribuição de destinadores e agrupamento em viagens de ida e volta com um único destino. O NSGA-II é empregado como método de busca das alternativas de compromisso [Deb et al., 2002]. A literatura de transporte de materiais perigosos também mostra a relevância de otimizar custo e risco conjuntamente [Chai et al., 2023].

2. Relação com a formulação de Rabbani et al.

O modelo de Rabbani et al. [2018] apresenta três objetivos, mas com uma ordem diferente daquela adotada neste protótipo. O custo total corresponde às Equações (1a)–(1g) do artigo; o *risco das instalações* às Equações (2a)–(2b); e o *risco de transporte* às Equações (3a)–(3b). Na implementação experimental deste trabalho, o vetor é ordenado como custo (f_1), transporte (f_2) e instalações (f_3). Essa permutação de índices não altera a natureza multiobjetivo do problema.

Tabela 1: Correspondência entre o modelo de referência e o protótipo.

Grandeza	**Rabbani et al. (2018)**	**Implementação experimental**
Custo	f_1: transporte, fluxos entre instalações e implantação	f_1: destinação por massa e custo por viagem
Risco de instalações	f_2: risco de sítios segundo exposição populacional	f_3: coeficiente sintético por kg destinado
Risco de transporte	f_3: risco das rotas e exposição da população	f_2: distância, carga e coeficiente viário simulado
Decisões	localização, tecnologia, rotas, fluxos	destinador e prioridade de agrupamento

O artigo original possui, entre outras, variáveis de abertura de instalações, escolha de tecnologia, encaminhamento de resíduos entre instalações e arcos percorridos por veículos. Esses elementos *não* estão representados diretamente no cromossomo do protótipo. Portanto, as expressões apresentadas a seguir são uma *formulação da implementação simplificada*, e não transcrições das equações originais.

3. Modelo experimental correspondente à avaliação computacional

3.1. Conjuntos, parâmetros e representação

Sejam L os lotes e I as instalações previamente disponíveis. Cada lote $l \in L$ possui massa $q_l > 0$, tipo w_l e recebe um destino $y_l \in I$. A instalação i tem capacidade K_i, custo de tratamento a_i por unidade de massa, coeficiente de risco local s_i, distância de ida d_i e coeficiente viário ρ_i. O veículo possui capacidade Q, custo fixo por viagem b e custo por quilômetro c. O cromossomo também atribui uma prioridade π_l a cada lote. A prioridade ordena os lotes destinados à mesma instalação para um procedimento construtivo de alocação *first-fit*.

Para cada destino i, o procedimento forma um conjunto T_i de viagens, cada uma com apenas aquele destino, sem exceder Q e sem reunir pares de tipos incompatíveis. Seja $T = \bigcup_{i \in I} T_i$, $i(t)$ o destino da viagem t e $M_t = \sum_{l \in t} q_l$ a massa nela transportada. As variáveis y_l e π_l caracterizam a codificação; as viagens são derivadas por heurística, não otimizadas por um problema de roteirização em grafo.

3.2. Funções objetivo efetivamente implementadas

De acordo com a rotina de avaliação do protótipo, o custo é composto de tratamento e viagens:

$$\min f_1(y,\pi) = \sum_{l\in L} q_l a_{y_l} + \sum_{t\in T(y,\pi)} \big(b + 2d_{i(t)}c\big). \tag{1}$$

O risco de transporte é calculado somando a distância de ida e volta multiplicada pela carga e pelo coeficiente de risco da instalação de destino:

$$\min f_2(y,\pi) = \sum_{t\in T(y,\pi)} 2d_{i(t)}\rho_{i(t)}M_t. \tag{2}$$

O risco das instalações é uma soma ponderada pela massa destinada:

$$\min f_3(y,\pi) = \sum_{l\in L} q_l s_{y_l}. \tag{3}$$

O vetor objetivo é $\min F = (f_1, f_2, f_3)$. A Equação (1) não inclui abertura de novas instalações ou custos de transferência entre unidades. A Equação (2) não modela explicitamente população exposta ao longo de arcos da rede, e a Equação (3) não calcula risco de sítio a partir de habitantes no entorno. Esses termos são aproximações sintéticas, ainda que inspiradas nas categorias de risco de Rabbani et al. [2018].

3.3. Restrições e construção de viagens

Cada lote recebe exatamente um destino admissível, segundo a codificação $y_l \in I$. Definindo $A_{li} = 1$ se a instalação i aceita o tipo w_l e zero caso contrário, impõe-se $A_{l,y_l} = 1$. A capacidade das instalações exige

$$\sum_{l:y_l=i} q_l \le K_i, \qquad \forall i \in I. \tag{4}$$

Para cada viagem construída $t \in T$, a carga deve satisfazer

$$\sum_{l\in t} q_l \le Q. \tag{5}$$

Se $H_{lk} = 1$ representa incompatibilidade entre dois lotes distintos, a composição de viagens deve atender

$$H_{lk} = 1 \implies \nexists t \in T : \{l,k\} \subseteq t. \tag{6}$$

A implementação verifica a admissibilidade dos destinos, calcula excesso de capacidade como violação e evita reunir lotes incompatíveis no procedimento de agrupamento. Portanto, *nem todas as restrições são impostas por um solucionador de programação matemática*: parte delas é tratada durante a construção das viagens e parte pela comparação de viabilidade no algoritmo evolutivo. Não se deve confundir o protótipo com o modelo MIP completo de Rabbani et al. [2018].

4. Algoritmo NSGA-II e rastreabilidade

O NSGA-II combina ordenação por não dominância, distância de aglomeração e seleção ambiental elitista [Deb et al., 2002]. Na aplicação, cada indivíduo é o par de vetores (y, π). A avaliação transforma o cromossomo em viagens e calcula F, o número de viagens e violações. Os operadores de cruzamento e mutação alteram os genes, que são novamente avaliados.

As dez etapas documentadas são: (1) população inicial, (2) codificação, (3) avaliação, (4) torneio, (5) cruzamento, (6) mutação, (7) ordenação por não dominância, (8) distância de

aglomeração, (9) seleção ambiental e (10) parada. Essa lista é didática, não uma ordem de execução única: ordenação e distância de aglomeração também são calculadas para classificar os pais antes do torneio.

Para minimização, uma solução viável u domina outra solução viável v se

$$\big[\forall m \in \{1,2,3\},\ f_m(u) \le f_m(v)\big] \wedge \big[\exists m,\ f_m(u) < f_m(v)\big]. \tag{7}$$

A distância de aglomeração usa, em cada frente, a soma das diferenças normalizadas entre vizinhos ordenados em cada objetivo. As soluções extremas recebem distância infinita, favorecendo a preservação da diversidade [Deb et al., 2002]. A seleção ambiental combina população parental P_t e descendentes Q_t em $R_t = P_t \cup Q_t$, e conserva N indivíduos priorizando melhores frentes e, na frente de corte, maior distância de aglomeração.

5. Experimentos e resultados

Foram empregados dois cenários ilustrativos com sete lotes, seis instalações e capacidade veicular de 150 kg. O cenário A é uma construção hipotética associada à embarcação denominada MV SSL Thamirabarani, cuja documentação necessita de conferência; o cenário B utiliza como referência um inventário-modelo de embarcação japonesa. Em ambos os cenários, parâmetros logísticos, instalações, valores de risco e matriz de incompatibilidades são simulados.

A execução didática A, com 8 indivíduos e 3 gerações, registrou 8 indivíduos viáveis na primeira frente da geração inicial e 8 soluções não dominadas viáveis distintas ao final. Os mínimos individuais $f_1 = 9154$, $f_2 = 148{,}348$ e $f_3 = 17{,}015$ permaneceram constantes no rastreamento apresentado. Esses mínimos podem corresponder a indivíduos distintos e não demonstram convergência.

A execução principal utilizou $N = 100$, limite de 200 gerações e semente pseudoaleatória 20261102. Os resultados informados pelo programa são apresentados na Tabela 2.

Tabela 2: Resultados da execução principal: valores associados à solução de menor custo de cada frente.

Indicador	**Cenário A**	**Cenário B**
Soluções não dominadas viáveis distintas	55	68
Menor custo na frente	8853,00	5434,80
Risco de transporte associado	172,06	78,78
Risco das instalações associado	16,37	11,17
Número de viagens associado	5	3

O número de soluções não dominadas refere-se à saída deduplicada reportada na execução e não é uma medida de proximidade com uma fronteira ótima conhecida. Como os cenários não são instâncias idênticas, suas diferenças numéricas não demonstram superioridade do NSGA-II em um caso. Também não foram realizadas múltiplas sementes nem comparação estatística com outra meta-heurística neste experimento.

6. Conclusão

A implementação permite rastrear uma adaptação da logística de resíduos perigosos em termos de custo, risco de transporte e risco de instalações. A revisão das equações evidencia que as três categorias de objetivos coincidem com a discussão de Rabbani et al. [2018], mas a estrutura matemática, a ordem dos riscos, a representação das decisões e a rede considerada são diferentes. O protótipo não reproduz a localização e roteirização completas da referência. Para avançar da demonstração computacional à decisão logística, são necessários dados reais verificados, modelagem de rotas em rede, calibração de risco, múltiplas execuções e comparação com métodos alternativos.

Referências

Chai, H., He, R., Kang, R., Jia, X., e Dai, C. (2023). Solving bi-objective vehicle routing problems with driving risk consideration for hazardous materials transportation. *Sustainability*, 15(9):7619.

Deb, K., Pratap, A., Agarwal, S., e Meyarivan, T. (2002). A fast and elitist multiobjective genetic algorithm: NSGA-II. *IEEE Transactions on Evolutionary Computation*, 6(2):182–197.

Rabbani, M., Heidari, R., Farrokhi-Asl, H., e Rahimi, N. (2018). Using metaheuristic algorithms to solve a multi-objective industrial hazardous waste location-routing problem considering incompatible waste types. *Journal of Cleaner Production*, 170:227–241.